

1. Inleiding

De veroudering van de bevolking in de Vlaamse steden en gemeenten zet zich in de komende decennia verder. (StatistiekVlaanderen, 2018) Volgens hun voorspellingen zou tegen 2033 25% van de bevolking een 65-plusser zijn.

Het woord ‘waardigheid’ is actueler dan ooit. Na de schrijnende omstandigheden van de Tweede Wereldoorlog stond dat woord centraal bij het opstellen van het verdrag van de Verenigde Naties (1945), de Universele Verklaring van de Rechten van de mens (1948) en de grondrechten van de Europese Unie (2000). Die basiswaarde vinden we ook terug bij het Europese en Belgische zorgbeleid. Ouderen mogen niet gediscrimineerd worden op vlak van leeftijd. Tevens mogen ze ook niet op een kinderlijke, betuttelende of onvriendelijke wijze aangesproken worden en moeten ze met respect bejegend worden (Campens, g.d.).

Hoe meer ouderen er in de samenleving zijn, hoe meer zorg zij nodig hebben en hoe meer zorgverleners instaan voor deze leeftijdscategorie. Die zorgverleners, maar evengoed familie, weten niet altijd even goed hoe ze moeten omgaan met senioren. Wanneer een jonger persoon op een andere manier spreekt tegen een senior dan tegen een leeftijdsgenoot, spreken we over *elderspeak*. Williams (2011) omschrijft *elderspeak* als volgt: “Elderspeak is a common intergenerational speech style used by younger persons in communication with older adults in a variety of community and health care settings. Based on negative stereotypes of older adults as less competent communicators, younger speakers (in this case nursing home staff) modify their communication with nursing home residents by simplifying the vocabulary and grammar and by adding clarifications such as repetitions and altered prosody.” Om *elderspeak* te bestrijden, gaven Wick en Zanni (2007) een paar tips mee in hun onderzoek. Enkele van die tips gingen als volgt: spreek mensen aan zoals ze wensen aangesproken te worden, vraag om ze aan te spreken met

de voornaam, vermijd troetelnamen, wees bewust van non-verbaal gedrag, verhoog uw stemvolume enkel wanneer uw gesprekspartner hardhorig is, herhaal alleen uw zin als uw gesprekspartner het niet begrepen heeft, vermijd korte, langzame en makkelijke zinnen, vermijd verkleinwoorden en hanteer beleefd taalgebruik.

Naast *elderspeak* heb je ook nog *nursery tone*. Dit verwijst naar de situatie waarbij iemand de toonhoogte aan het einde van de zin standaard verhoogt zoals bij communicatie met jonge kinderen.

Dit onderwerp was vorig jaar al een onderzoeksonderwerp voor Glenn Beeckman (2021) en Victor Standaert (2021). Zij hebben al een basis gelegd in de goede richting om dit project tot een goed einde te brengen. Sommige stukken programmacode van hen zullen gebruikt worden om zo een beter model op te stellen. Zij haalden zelf ook verbeterpunten aan en moeilijkheden die, hopelijk, op te lossen zijn. Wat het verschil zal zijn tussen hun eindwerken en dit eindwerk wordt toegelicht in A.2.

De nog steeds relevante onderzoeksvraag van dit onderwerp is: “Kan *elderspeak* gedetecteerd worden door Artificiële Intelligentie en kan dit toegepast worden in de praktijk?”. Een bijkomende onderzoeksvraag is: “Kan *nursery tone* gedetecteerd worden door Artificiële Intelligentie?”.

De inleiding moet de lezer net genoeg informatie verschaffen om het onderwerp te begrijpen en in te zien waarom de onderzoeksvraag de moeite waard is om te onderzoeken. In de inleiding ga je literatuurverwijzingen beperken, zodat de tekst vlot leesbaar blijft. Je kan de inleiding verder onderverdelen in secties als dit de tekst verduidelijkt. Zaken die aan bod kunnen komen in de inleiding (**Pollefliet2011**):

- context, achtergrond
- afbakenen van het onderwerp
- verantwoording van het onderwerp, methodologie
- probleemstelling
- onderzoeksdoelstelling
- onderzoeksvraag
- ...

1.1 Probleemstelling

Dit onderzoek zal een meerwaarde moeten betekenen voor de oudere mensen in rusthuizen, homes, ziekenhuizen, maar ook nog de ouderen die zelfstandig thuis wonen. Deze mensen vinden het namelijk helemaal niet leuk om behandeld te worden als kleine kinderen. Deze applicatie zou dan *elderspeak* moeten herkennen en aangeven welke eigenschappen het model gevonden heeft. Het zijn dan vooral de verpleegkundigen, dokters, maar ook familieleden die zich bewust moeten zijn hoe ze tegen ouderen praten.

Uit je probleemstelling moet duidelijk zijn dat je onderzoek een meerwaarde heeft voor een concrete doelgroep. De doelgroep moet goed gedefinieerd en afgeijnd zijn. Doel-

groepen als “bedrijven,” “KMO’s,” systeembeheerders, enz. zijn nog te vaag. Als je een lijstje kan maken van de personen/organisaties die een meerwaarde zullen vinden in deze bachelorproef (dit is eigenlijk je steekproefkader), dan is dat een indicatie dat de doelgroep goed gedefinieerd is. Dit kan een enkel bedrijf zijn of zelfs één persoon (je co-promotor/opdrachtgever).

1.2 Onderzoeksvraag

De onderzoeksvraag die bij dit eindwerk hoort is: “Kan *elderspeak* gedetecteerd worden door Artificiële Intelligentie en kan dit toegepast worden in de praktijk?”. Een bijkomende onderzoeksvraag is: “Kan *nursery tone* gedetecteerd worden door Artificiële Intelligentie?”. Maar alleen dit beantwoorden zal uiteraard niet genoeg zijn. Het beantwoorden van de volgende deelvragen zullen wel een duidelijker en uitgebreider antwoord geven op de algemene probleemstelling:

- Welk type Artificiële Intelligentie past het beste bij deze opstelling?
- Welk type model van *machine learning* of *deep learning* werkt het beste per eigenschap?
- Hoe zitten de Python bibliotheken in elkaar die gebruikt werden in het project?
- Kan je achtergrond lawaai wegfilteren en hoe precies?
- Zal spraakherkenning lukken met de gratis beschikbare softwarebibliotheken?
- Hoe zet je een “Flask” server op waar je *webrequests* naar stuurt? En hoe verbind je daar een model mee?

Wees zo concreet mogelijk bij het formuleren van je onderzoeksvraag. Een onderzoeksvraag is trouwens iets waar nog niemand op dit moment een antwoord heeft (voor zover je kan nagaan). Het opzoeken van bestaande informatie (bv. “welke tools bestaan er voor deze toepassing?”) is dus geen onderzoeksvraag. Je kan de onderzoeksvraag verder specificeren in deelvragen. Bv. als je onderzoek gaat over performantiemetingen, dan

1.3 Onderzoeksdoelstelling

Het resultaat van deze bachelorproef is een basiswebsite die dient als *PoC* of *proof-of-concept*. Die basisapplicatie vraagt eerst om gewoon te praten zoals je zou doen tegen je vrienden. Nadien wordt er gevraagd om te praten zoals je zou doen bij slechthorende senioren in een rusthuis. Om dat gevoeld te versterken zal er een foto getoond van iemand uit een rusthuis. De applicatie analyseert dan de audiosamples en geeft aan welke kenmerken er aanwezig waren van *elderspeak*. Die kenmerken van *elderspeak* en waarom het model ‘denkt’ dat die eigenschappen aanwezig zijn, zijn vergaard in het literatuuronderzoek. Al de voorgaande zaken moet voor de deadline van de bachelorproef afgewerkt worden opdat het een succes kan genoemd worden.

Wat is het beoogde resultaat van je bachelorproef? Wat zijn de criteria voor succes?

Beschrijf die zo concreet mogelijk. Gaat het bv. om een proof-of-concept, een prototype, een verslag met aanbevelingen, een vergelijkende studie, enz.

1.4 Opzet van deze bachelorproef

De rest van deze bachelorproef is als volgt opgebouwd:

In Hoofdstuk 2 wordt een overzicht gegeven van de stand van zaken binnen het onderzoeksdomein, op basis van een literatuurstudie.

In Hoofdstuk 3 wordt de methodologie toegelicht en worden de gebruikte onderzoekstechnieken besproken om een antwoord te kunnen formuleren op de onderzoeksvragen.

In Hoofdstuk 4, tenslotte, wordt de conclusie gegeven en een antwoord geformuleerd op de onderzoeksvragen. Daarbij wordt ook een aanzet gegeven voor toekomstig onderzoek binnen dit domein.

2. Stand van zaken

Dit hoofdstuk bevat je literatuurstudie. De inhoud gaat verder op de inleiding, maar zal het onderwerp van de bachelorproef **diepgaand** uitspitten. De bedoeling is dat de lezer na lezing van dit hoofdstuk helemaal op de hoogte is van de huidige stand van zaken (state-of-the-art) in het onderzoeksdomein. Iemand die niet vertrouwd is met het onderwerp, weet nu voldoende om de rest van het verhaal te kunnen volgen, zonder dat die er nog andere informatie moet over opzoeken (**Pollefliet2011**).

Je verwijst bij elke bewering die je doet, vakterm die je introduceert, enz. naar je bronnen. In \LaTeX kan dat met het commando `\textcite{}` of `\autocite{}`. Als argument van het commando geef je de “sleutel” van een “record” in een bibliografische databank in het Bib \LaTeX -formaat (een tekstbestand). Als je expliciet naar de auteur verwijst in de zin, gebruik je `\textcite{}`. Soms wil je de auteur niet expliciet vernoemen, dan gebruik je `\autocite{}`. In de volgende paragraaf een voorbeeld van elk.

Knuth1998 schreef een van de standaardwerken over sorteer- en zoekalgoritmen. Experten zijn het erover eens dat cloud computing een interessante opportuniteit vormen, zowel voor gebruikers als voor dienstverleners op vlak van informatietechnologie (**Creeger2009**).

2.1 Verkennend onderzoek

“Kan *elderspeak* gedetecteerd worden door Artificiële Intelligentie en kan dit toegepast worden in de praktijk?”, is de centrale onderzoeksvraag, maar daarvoor moeten we twee begrippen goed uitleggen en begrijpen om te kunnen staven of dit wel degelijk mogelijk is. Er zal dus eerst beschreven worden wat *elderspeak* precies is. Waarom vinden ouderen dat

niet leuk? Wat zijn de eigenschappen en hoe kan je het voorkomen? Daarnaast moeten we ook begrijpen wat Artificiële Intelligentie is met daarbij alle verschillende types, vormen en maten ervan. De reden hiervoor is dat er verstaan moet worden welke en hoe AI gebruikt werd in het eindresultaat.

2.2 Elderspeak

2.2.1 Wat is *Elderspeak*?

Het begrip *elderspeak*, ook *secondary babytalk* genoemd, kent verschillende definities. Kemper e.a. (1998) omschrijft het begrip als volgt: “Elderspeak is a simplified speech register with exaggerated pitch and intonation, simplified grammar, limited vocabulary and slow rate of delivery.”

Daarnaast beschrijft Williams (2011) het begrip als het volgende: “Elderspeak is a common intergenerational speech style used by younger persons in communication with older adults in a variety of community and health care settings. Based on negative stereotypes of older adults as less competent communicators, younger speakers (in this case nursing home staff) modify their communication with nursing home residents by simplifying the vocabulary and grammar and by adding clarifications such as repetitions and altered prosody.”

2.2.2 Wat zijn de kenmerken?

Deze kenmerken komen overeen met een communicatiestijl die men hanteert wanneer men tegen (afhankelijke) kinderen praat. Vandaar dat *elderspeak* ook wel als *secondary baby talk* wordt benoemd. Die kenmerken zijn hieronder opgesomd:

- Langzaam spreken
- Verhoogde toonhoogte
- Verhoogd stemvolume
- Overdreven intonatie
- Vereenvoudigd woordgebruik, gebruik van verkleinwoorden en/of ongepaste bijnamen of troetelnamen
- Verminderde grammaticale complexiteit (bv. voornamelijk enkelvoudige zinnen)
- Gebruik van collectieve voornaamwoorden (bijvoorbeeld “we” in plaats van “jij”)
- Veelvuldig gebruik van (bevestigende) tussenwerpsels (zoals “hé” of “voilà”)
- Gewijzigd non-verbaal gedrag (bv. langdurig oogcontact, extra gebaren, te dichtbij komen)
- Veelvuldige verduidelijking en herhaling

(Campens, 2021)

Tenslotte is het belangrijk om te weten dat bij *elderspeak* de inhoud van de boodschap, die

de zorgverlener wil overbrengen, niet wijzigt. Wel verandert de wijze waarop de boodschap wordt overgebracht door het gebruik van een infantiliserende communicatiestijl, aldus Campens (2021).

2.2.3 Wat zijn de tips om *elderspeak* te voorkomen?

De onderstaande tips zijn enkele van de tips die Wick en Zanni (2007) meegeven ter “bestrijding” van *elderspeak*:

- Spreek personen aan met de naam waarmee ze willen aangesproken worden. Gebruik geen collectieve voornaamwoorden als die niet van toepassing zijn.
- Als een persoon een zorgverlener toelaat om hem of haar met zijn voornaam aan te spreken, ga er dan niet van uit dat deze toestemming voor alle zorgverleners geldt. De mate van intimiteit varieert, waardoor elke zorgverlener moet nagaan hoe hij of zij zijn gesprekspartner mag aanspreken.
- Vermijd het gebruik van troetelnamen en overmatige intieme liefkozingen, tenzij de gesprekspartner uitdrukkelijk aangeeft dat hij of zij zo wil aangesproken worden.
- Wees je bewust van je non-verbaal gedrag.
- Verhoog je stemvolume (in beperkte mate) enkel en alleen wanneer de gesprekspartner hardhorig is. Verhoging van je stemvolume betekent geen verhoging van je stemhoogte. Wees je ervan bewust dat niet elke oudere gesprekspartner hardhorig is.
- Herhaling en verminderde grammaticale complexiteit hebben een plaats als de gesprekspartner je niet begrepen heeft.
- Vermijd korte zinnen en langzaam en met overdreven intonatie uitgesproken zinnen.
- Vermijd het gebruik van verkleinwoorden, aangezien die het gevoel van afhankelijkheid kunnen versterken en denigrerend kunnen geïnterpreteerd worden.
- Vermijd overdreven directieve boodschappen en bied keuzevrijheid.
- Hanteer een beleefd taalgebruik en beleefde omgangsvormen (bv. op de kamerdeur kloppen alvorens de kamer binnen te gaan).

2.3 Artificiële Intelligentie

2.3.1 Wat is AI?

Er zijn bijzonder veel beschrijvingen rond wat AI is, maar alleen uit verschillende bronnen kan je een accuraat beeld krijgen van wat AI precies is.

Volgens Oracle (2014) heeft AI (kunstmatige intelligentie) betrekking op systemen of machines die onze eigen intelligentie nabootsen om taken uit te voeren en die zichzelf tijdens dat proces kunnen verbeteren op basis van de vergaarde informatie.

Het Europees Parlement (2020) geeft de volgende definitie aan artificiële intelligentie (of kunstmatige intelligentie): “AI is de mogelijkheid van een machine om mensachtige vaardigheden te vertonen - zoals redeneren, leren, plannen en creativiteit. AI maakt het voor technische systemen mogelijk om hun omgeving waar te nemen, om om te gaan met deze waarnemingen en problemen op te lossen om een specifiek doel te bereiken. De computer ontvangt data - reeds voorbereid en verzameld via eigen sensoren, zoals een camera - verwerkt deze en reageert erop. AI-systemen zijn in staat om hun gedrag in zekere mate aan te passen door het effect van vorige acties te analyseren en autonoom te werken.”

Samengevat is AI een technisch systeem om onze eigen intelligentie na te bootsen op basis van vergaarde informatie en waarbij het systeem acties aanpast op die data.

2.3.2 Welke vormen zijn van AI?

Artificiële Intelligentie is een verzamelnaam voor 2 soorten. Zo heb je enerzijds *machine learning* en anderzijds *deep learning* (Kavlakoglu, 2020). Dit kan mooi geïllustreerd worden a.d.h.v. figuur 2.1. Daarop kan er afgeleid worden dat Artificiële Intelligentie een verzamelnaam is. Specifieker heb je dan *machine learning* en daaronder heb je nog *deep learning*.

2.3.3 Machine learning

Machine learning of machinaal leren is het deelgebied van kunstmatige intelligentie dat computers het vermogen geeft te leren zonder expliciet geprogrammeerd te zijn, aldus Lievens (2021). Machinaal leren heeft drie types namelijk *supervised learning* of gesuperviseerd leren, *unsupervised learning* of leren zonder toezicht en als laatste type is er *reinforcement learning* of leren door bekrachtiging.

Supervised learning

Een defenitie gegeven door Lievens (2021) over *supervised learning* gaat als volgt: “De taak van *supervised learning* is een hypothese op te bouwen op basis van een reeks gelabelde trainingsgegevens. Deze hypothese kan dan worden gebruikt om het label voor een



Figuur 2.1: Soorten AI in diagram (Bansal, 2019)

(nieuwe) input te voorspellen. Wanneer het label een reëel getal is, spreekt men van een regressieprobleem; wanneer het label beperkt is tot een (beperkt) aantal vooraf gedefiniëerde klassen, wordt het probleem een classificatieprobleem genoemd.”

Een voorbeeld van het regressieprobleem is het voorspellen van huisprijzen. De input van het model is dan een reeks vectoren die de eigenschappen van het huis voorstellen zoals aantal slaapkamers, oppervlakte, bouwjaar etc.

Voorbeelden van het classificatieprobleem zijn spam detectie, nummerherkenning of diabetes aan de hand van een specifieke reeks vectoren die eigenschappen bepalen. Bij spam detectie zijn er twee vooraf gedefiniëerde klassen: spam en geen spam. Bij het herkennen van nummers zijn er 10 klassen: 0 t.e.m. 10 en bij diabetesdetectie kunnen er drie klassen aanwezig zijn namelijk geen diabetes, diabetes en pre-diabetes.

Unsupervised learning

Lievens (2021) omschrijft *unsupervised learning* als de taak van het ontdekken van structuur in een ongelabelde gegevensreeks.

De meest prominente taak bij *unsupervised learning* is *clustering*, d.w.z. de ontdekking van coherente groepen. Andere mogelijke taken zijn anomalie detectie en hoofdcomponentenanalyse (PCA).

Een voorbeelden van clustering is markt segmentatie waarbij klanten worden opgedeeld in verschillende segmenten zoals trouwe klant, mogelijke vertrekkende klant, niet tevreden

klant etc. Op basis van aankoopdata, tijdstippen en online activiteit kan men de klanten gaan indelen in clusters. Die informatie kan dan weer gebruikt worden om bepaalde clusters meer informatie te geven of korting te geven. Er zijn algoritmen die fraude opsporen op een website die vreemd gedrag gaan detecteren, wat dan een voorbeeld van anomalie detectie is. Bij PCA worden de data gereduceerd zodat de minder relevante data afneemt in de dataset, maar de nodige data juist duidelijker maakt.

Reinforcement learning

Lievens (2021) beschrijft leren door bekrachtiging door een techniek dat niet echt een dataset gebruikt, maar dat het eerder een identiteit is die leeft in een (on)bekende wereld die beloningssignalen krijgt. De opdracht is dan om uit te zoeken wat de regels zijn die leiden tot een grote beloning.

Het bekendste voorbeeld van *reinforcement learning* is zelfrijdende wagens waarbij het model alles zelf moet aanleren zoals het remmen en gas geven in welke hoeveelheid en hoe er gestuurd moet worden. Dit is een lang en iteratief proces waarbij het model dus de hele tijd zichzelf bijstuurt en bijleert van wat hij net gezien heeft.

2.3.4 Deep Learning


Deep learning is een onderdeel van *machine learning* die neurale netwerken bevat. “Een artificieel neurale netwerk bestaat uit een groot aantal eenvoudige rekende eenheden, units of neuronen die de volgende eigenschap heeft: ‘Als de (gewogen) input van een neuron groot is, zal het ‘vuren’ en dit neuron zal een grote waarde op zijn axon zetten. Bovendien zijn deze eenheden verbonden door middel van gerichte links waarbij een reëel getal de sterkte van elke verbinding aangeeft.”, aldus Lievens (2021) in zijn cursus *Distributed Databases*.

De systematische voorstelling van een neuron is te vinden in figuur 2.2. Een volledig neurale netwerk kan er uit zien zoals in figuur 2.3. De data wordt gevoed aan de *input layer*. Daarna komen een x-aantal *hidden layers* die dan de bewerkingen uitvoeren en als laatste stap heb je de *output layer*. Het aantal *nodes* of knopen in de *output layer* is gelijk aan het aantal klassen die een probleem heeft. Als er een *deep learning* model gemaakt wordt van het detecteren van spam, dan zou de *output layer* twee knopen moeten hebben.


2.3.5 AI in het dagelijkse leven

Om een klein overzicht te maken wat AI allemaal inhoudt, zijn er andere voorbeelden geïllustreerd van kunstmatige intelligentie in figuur 2.4. TODO: meer informatie geven of weglaten?

Schematic Diagram of a Neuron

**HO
GENT**

Figuur 2.2: Systematische voorstelling van een Neuron (Lievens, 2021)



Figuur 2.3: Layers van een artificieel neurale netwerk (Lievens, 2021)



Figuur 2.4: AI in het dagelijkse leven. (Europees Parlement, 2020)

2.4 AI technieken die gebruikt worden om elderspeak te detecteren

2.4.1 NLP of *natural language processing*

Om te kunnen detecteren of men verkleinwoorden, troetelnamen, collectieve voornaamwoorden of veel tussenwerpsels gebruikt, moet het model of eerder gezegd de Python bibliotheek - die het model bevat - weten of deze eigenschappen voorkomen. Hiervoor moeten we gebruik maken van *natural language processing* bibliotheken of kort NLP. Maar wat is NLP precies?

Natural language processing of vertaald “natuurlijke taalverwerking” zit in de tak van de computerwetenschappen, meer bepaald de tak van de kunstmatige intelligentie. NLP zit binnen de bubbel van AI, heeft een stuk *machine learning* en een stukje *deep learning*. (Kleinings, 2022) De visuele voorstelling van die verhoudingen zijn te vinden in figuur 2.5.

Volgens Kleinings (2022) is die natuurlijke taalverwerking een technologie die gebruikt wordt om computers te helpen om natuurlijke menselijke taal te begrijpen en te interpreteren.


NLP combineert computationele linguïstiek - op regels gebaseerde modellering van menselijke taal - met statistische, *machine learning*- en *deep learning*-modellen. Samen stellen deze technologieën computers in staat menselijke taal - in de vorm van tekst of spraakgegevens - te verwerken en de volledige betekenis ervan te “begrijpen”, compleet met de bedoeling en het sentiment van de spreker of schrijver. (Cloud-Education IBM, 2021)

NLP stuurt computerprogramma's aan die tekst van de ene taal naar de andere vertalen, reageren op gesproken opdrachten en grote hoeveelheden tekst kan samengevat worden, zelfs in realtime. Enkele voorbeelden van NLP-systemen in het dagelijkse leven zijn: spraakgestuurde GPS-systemen, digitale assistenten, spraak-naar-tekst dicteersoftware in bijvoorbeeld de smartphone of Microsoft Word, chatbots voor de klantenservice en andere gemakken voor de consument. Maar NLP speelt ook een steeds grotere rol in bedrijfsoplossingen die helpen bij het stroomlijnen van de bedrijfsvoering, het verhogen van de productiviteit van werknemers en het vereenvoudigen van bedrijfskritische bedrijfsprocessen, aldus Cloud-Education IBM (2021).

Waarom is het analyseren van taal moeilijk?

Volgens Kleinings (2022) zijn er vele redenen waarom het verwerken van taal door een computer of AI-systeem nog steeds moeilijk is en zal blijven.

Eerst en vooral heb je alle linguïstische regels per taal. Zo zijn er meer dan 6500 talen die nog steeds gesproken worden vandaag de dag, die dus elke hun aparte regels hebben. Daarnaast is er het probleem van de uniformiteit. Om taal te kunnen verwerken moet die eerst omgezet worden in een systeem of formaat dat de computer kan begrijpen. Door middel van machinaal leren identificeert het model ongestructureerde taal en zet deze om



Figuur 2.5: Situering van NLP binnen het AI-veld. (Kleinings, 2022)

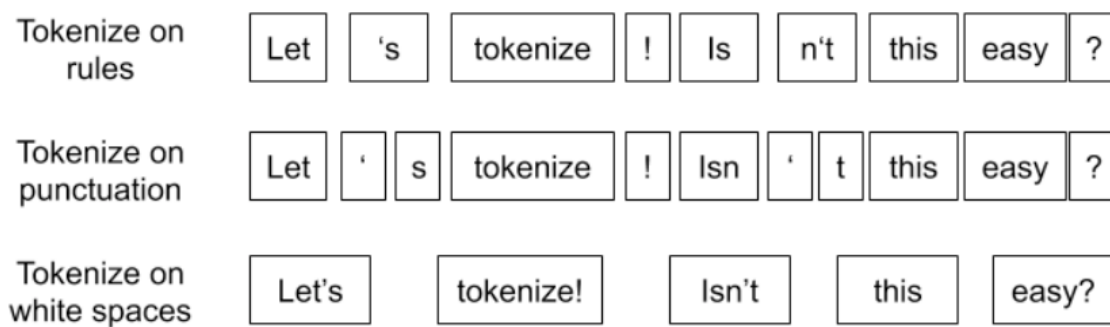
naar bruikbare, niet dubbelzinnige informatie die de computer dan kan begrijpen en er verder mee kan rekenen. Dit stukje wordt de *pre-processing* genoemd.

Bovendien speelt de context ook vaak parten. *Natural Language Processing* werkt fundamenteel door de hiërarchie van linguïstische dictie tussen elk woord te begrijpen en deze om te zetten in een vorm die computers kunnen interpreteren. Onze talen zijn niet eenvoudig, zo hebben woorden meerdere betekenissen, die alleen begrepen worden door het verschil in context. (Kleinings, 2022) Een voorbeeld hiervan is het woord “bank”. In de ene context is het de financiële instelling en in een andere context is het de rustbank in het park. Als laatste kan de toon van de stem ook nog verschillen. Mensen kunnen sarcasme of ironie in hun taal steken zodat het een andere betekenis krijgt. Om deze andere betekenis uit een tekst te halen is er heel veel moeite voor nodig.

Hoe werkt NLP?

NLP is niet één statische methode, maar een ketting van manipulaties van de tekst zodat er meer lagen informatie tevoorschijn komen. Dit wordt gerealiseerd met neurale netwerken waarbij elke node een bepaalde functie uitvoert. Er zijn vier grote stappen i.v.m. de taalverwerking: morfologie, syntaxis, semantiek en pragmatiek, schrijft Kleinings (2022), wat te lezen is op een *low-code/no-code* platform genaamd Levity die dus veel kennis hebben over AI. Daar kan men blokken slepen en gebruiken om een AI-model op te stellen.

Met behulp van morfologie kan er per woord een type geclassificeerd worden zoals een zelfstandig naamwoord, bijvoeglijk naamwoord, voornaamwoord, lidwoord enzovoort. Wat dit markeren juist moeilijker maakt is de context waarin het woord gebruikt wordt. Denk hierbij aan het voorbeeld met de bank.




Let's tokenize! Isn't this easy?

Figuur 2.6: Manieren om een zin om te delen volgens een *token*. (Horan, 2020)

Om de syntaxis aan te leren zijn er twee manieren om dit te verwezenlijken. Enerzijds kunnen er woorden gelabeld worden waarbij er gezegd wordt dat woord A de stam is, woord B de 2e persoon enkelvoud, woord C het voltooid deelwoord etc. Anderzijds kan er een *unsupervised machine learning* model gemaakt worden waarbij de computer de regels afleidt uit verschillende gelabelde teksten en die logica gebruikt om nieuwe, niet-gelabelde, teksten te begrijpen met dezelfde logica.

Daarnaast is het ook aan te raden dat stopwoorden verwijderd worden als het model de tekst wil begrijpen. Stopwoorden zoals “een, de, euh, inderdaad, echt, oké, eigenlijk, allee, etc.” moeten verwijderd worden. Daarbij aansluitend zijn er twee andere methoden. Enerzijds lemmatiseren waarbij werkwoorden naar de tegenwoordige tijd veranderd worden, en anderzijds stemming, waarbij er prefixen of affixen verwijderd worden, ook nodig om de conversie te maken. Een voorbeelden van het converteren is dan: “wij dachten” naar “denk”. Woorden worden daarnaast ook vervangen door meer gebruikte synoniemen zoals van “enorm” naar “groot”.

Als laatste systeem of layer bestaat er *tokenization*. Dit is het proces waarbij het systeem de zin indeelt in verschillende eenheden waaruit informatie kan gehaald worden. Er kan een *token* gekozen worden op basis van regels, leestekens, spaties, maar dit geeft wel steeds een ander resultaat wat geïllustreerd is in figuur 2.6. Hoe die *tokenization* zich verhoudt met die layer van het *deep learning* NLP model is te vinden in figuur 2.7.



Figuur 2.7: Verhouding *deep learning* NLP model met de layers en de verschillende *tokens*. (Horan, 2020)

2.4.2 Filteren van achtergrond lawaai